

ENTERPRISE RAG UI DESIGN

企业级 RAG 系统 展示页面设计稿

目标：不是做一个普通聊天框，而是做一个面试官 3 分钟看懂、10 分钟看出技术深度、20 分钟相信具备生产意识的 RAG 演示系统。

极简问答入口

检索链路可观察

评测与性能报告

成本与稳定性意识



整体设计定位：前台极简，后台专业

企业级 RAG 系统不应该只有聊天框。更好的形态是：业务用户只看到简单问答；技术人员可以展开查看检索、排序、Prompt、成本、性能与评测结果。

业务用户视角

只关心能不能快速得到答案、答案有没有引用来源、是否可信。页面必须像 ChatGPT 一样轻。

一句话：少即是多

管理员视角

关心知识库是否建好、文档是否导入成功、索引是否可用、最近是否有失败任务。

一句话：状态要清楚

面试官视角

关心你是否理解 RAG 的工程闭环：导入、切分、检索、重排、生成、评测、观测、压测。

一句话：技术链路透明

1

文档接入

上传 Markdown / PDF / 文档，记录导入状态。

2

切分索引

Chunk、Embedding、BM25、Terms 等索引构建。

3

混合检索

Vector + BM25 + Hybrid 融合。

4

Reranker

对候选结果做二次排序，提高相关性。

5

回答生成

基于上下文拼 Prompt，返回引用和答案。

6

评测观测

命中率、延迟、Token、成本、QPS、瓶颈。

推荐页面结构：只保留 7 个核心入口

避免做成复杂 OA 后台

左侧菜单建议

Demo 总览

企业知识问答

知识库管理

检索调试

评测实验

成本分析

性能报告

系统配置

首页只展示 5 个卡片

开始问答
普通用户入口

检索调试
技术展示入口

评测实验
质量量化入口

性能报告
生产意识入口

面试演示路线

- 第 1 步：打开 Demo 总览页，让面试官一眼看到系统规模、延迟、成本、评测结果。
- 第 2 步：进入企业知识问答，输入一个真实问题，展示答案和引用来源。
- 第 3 步：点击“查看检索过程”，展示 Hybrid Search、Reranker、Prompt、Token。
- 第 4 步：进入评测实验，展示 TopK 命中率、答案可信度和失败样本。
- 第 5 步：进入性能报告，展示 QPS、P95、错误率、瓶颈和优化建议。
- 面试展示不要从代码讲起，而是从页面闭环讲起：先让对方看到产品，再解释背后的检索链路和工程设计。

Demo 总览页：3 分钟让面试官看懂系统

默认首页

Demo 总览

企业知识问答

知识库管理

检索调试

评测实验

性能报告

RAG Lab Platform

企业知识助手工作台 - 演示驾驶舱

开始一次问答

12

知识库
全部可用

520

文档数
中小企业模拟数据

50k

Chunk 数
已完成索引

82

最近评测得分
Hybrid + Reranker

快速提问

选择知识库：企业接口文档 / 输入问题：SMS_429 是什么意思？

Naive

向量检索基线

Hybrid

向量 + BM25

Reranker

重排增强

今日运行状态

指标	数值	说明
平均延迟	1.8s	问答链路总耗时
P95 延迟	2.9s	压测样本统计
平均成本	¥0.012	单次问答 Token 成本
错误率	0.3%	最近 24 小时

知识库管理

上传、切分、索引状态

检索调试

召回结果、分数、Prompt

评测实验

命中率、可信度、失败样本

性能报告

QPS、并发、系统瓶颈

企业知识问答页：普通用户只看到答案和证据

业务用户入口

设计重点：左侧选知识库，中间聊天，右侧展示引用来源。技术细节默认折叠，只保留“查看检索过程”按钮。

知识库

企业接口文档

产品使用手册

运维故障手册

人事制度

客服 FAQ

权限提示：仅展示当前用户可访问知识库。

企业知识助手

Hybrid + Reranker

SMS_429 是什么意思？需要怎么处理？

SMS_429 表示短信验证码发送触发了频率限制。系统会限制同一手机号、同一 IP 或同一设备在短时间内重复发送验证码。建议前端提示用户稍后重试，并在服务端保留限流日志用于排查。

已找到 3 条引用来源，置信度：较高。

继续追问：这个错误码对应的接口返回结构是什么？

引用来源

3 条

02-api-spec.md

chunk #23 / score 12.8

包含 SMS_429 错误码定义和限流说明。

03-error-code.md

chunk #8 / score 10.1

说明验证码错误码通用处理方式。

06-debug-log.md

chunk #41 / score 7.6

记录历史排查案例。

查看检索过程

知识库管理页：让文档生命周期可视化

管理员入口

Demo 总览

企业知识问答

知识库管理

检索调试

评测实验

性能报告

知识库管理

管理文档导入、分块、向量化、索引状态

上传文档

520

文档总数

50k

Chunk 总数

98%

索引成功率

12m

最近一次重建耗时

知识库	文档数	Chunk	Embedding	BM25	状态	操作
企业接口文档	126	12,840	qwen/text-embedding-v4	已构建	可用	详情 / 重建
运维故障手册	84	8,120	qwen/text-embedding-v4	已构建	可用	详情 / 重建
产品使用手册	210	21,300	qwen/text-embedding-v4	已构建	重建中	查看任务
客服 FAQ	100	7,740	qwen/text-embedding-v4	已构建	可用	详情 / 重建

上传后状态链路：

上传成功 -> 解析成功 -> 分块完成 -> 向量化完成 -> ES 索引完成 -> 可问答。

失败可排查：

失败文档、失败原因、重试入口、任务日志，让导入链路具备生产可维护性。

面试亮点：

知识库不是静态文件夹，而是有生命周期、有状态、有任务、有索引的资产。

检索调试页：这是最能体现技术深度的页面

技术展示核心

查询配置

问题：SMS_429 是什么意思？

Naive

BM25

Hybrid

Reranker

参数	值
topK	8
vectorWeight	0.55
bm25Weight	0.45
rerankTopN	5

展示目的：同一个问题，用不同检索模式对比结果，让面试官看到你理解召回和排序。

召回与重排结果

正确文档排第 1

02-api-spec.md / chunk #23

0.92

命中 terms: SMS_429；包含错误码解释和接口返回结构。

03-error-code.md / chunk #8

0.87

验证码错误码说明，包含通用处理建议。

06-debug-log.md / chunk #41

0.63

历史问题排查记录，相关但不是主文档。

01-project-guideline.md / chunk #5

0.31

项目规范，BM25 可能误召回，Reranker 降权。

142ms

BM25

238ms

Vector

310ms

Rerank

Prompt 与答案

System: 你是企业知识库助手。
Context:
[1] 02-api-spec.md ... SMS_429 表示发送频率限制 ...
[2] 03-error-code.md ... 验证码错误码处理 ...
Question: SMS_429 是什么意思?
要求: 只基于 Context 回答, 并给出引用。

Token	数量
Prompt Token	1,620
Completion Token	280
总成本	¥0.012

评测实验页：证明系统不是“感觉能用”

质量量化入口

Demo 总览

企业知识问答

知识库管理

检索调试

评测实验

性能报告

评测实验

用问题集批量评估不同检索模式和模型组合

运行评测

100

评测问题数

89%

Top3 命中率

84%

答案可信度

1.9s

平均耗时

不同检索模式对比



纵轴表示 Top3 命中率，展示从基线到增强方案的收益。

失败样本分析

问题	失败原因	优化建议
接口超时如何处理？	文档描述分散	补充 FAQ 聚合文档
某配置项默认值？	Chunk 切分过细	调整 overlap
权限错误排查？	召回结果太多	提高 rerank 权重

Retrieval: 看 Top1 / Top3 命中率，判断文档有没有召回对。

Generation: 看答案是否基于上下文，是否有幻觉。

Operation: 看成本、延迟和失败样本，决定下一步优化。

性能报告页：回答 QPS、并发量、系统极限在哪里

V12 展示重点

压测概览

模拟中小型企业知识库数据：520 文档 / 50,000 Chunk

报告已生成

38

稳定 QPS

100

最大并发

3.2s

P95 延迟

1.1%

错误率

并发压测曲线



并发 100 以内稳定；超过 150 后错误率和 P95 明显上升。

瓶颈分析与优化建议

瓶颈	现象	优化方向
LLM 响应	生成耗时占比最高	流式输出、模型降级、缓存
ES 检索	高并发下查询耗时上升	索引优化、字段加权、分页限制
DB 连接	日志写入有阻塞	异步日志、批量写入
Prompt 过长	Token 成本上升	上下文预算、动态 topK

面试讲法：

“我不是只测接口通不通，而是构造了中小型企业级知识库数据，再从 QPS、P95、错误率、Token 成本和瓶颈归因几个维度评估系统极限。”

报告输入：知识库规模、并发策略、测试问题集、检索模式。

报告输出：QPS、P50/P95/P99、错误率、成本、瓶颈、优化建议。

展示价值：体现生产压测思维和系统容量评估能力。

成本分析页：让大模型调用具备经营意识

生产化加分项

Demo 总览

企业知识问答

知识库管理

检索调试

评测实验

成本分析

性能报告

Token 与成本分析

按知识库、模型、检索模式统计调用成本

最近 7 天

1.8M

Prompt Token

420k

Completion Token

¥92.4

总成本

¥0.012

平均单次成本

不同模型成本对比

模型	用途	调用次数	成本
qwen/text-embedding-v4	Embedding	50,000	¥18.2
qwen-plus	问答生成	5,200	¥62.6
reranker	结果重排	4,800	¥11.6

成本优化策略

缓存：高频问题直接命中问答缓存。

动态 topK：简单问题少取上下文，复杂问题再扩大召回。

模型路由：普通问题用低成本模型，复杂问题升级模型。

上下文预算：限制 Prompt 长度，避免无效 Token。

面试亮点：企业级 AI 系统一定要算成本。你能展示 Token、模型、知识库、检索模式维度的成本统计，就比只会调 API 更像生产项目。

极简视觉规范：不要炫技，要像企业工具

页面统一规范

布局原则

首页：指标 + 快捷入口 + 快速提问。

问答页：左知识库、中聊天、右引用。

调试页：左参数、中结果、右 Prompt。

报告页：上核心指标，下瓶颈分析。

视觉原则

颜色：蓝灰白为主，少用大面积高饱和色。

字体：标题加粗，正文保持 12-14px。

卡片：轻阴影 + 圆角，像 SaaS 控制台。

状态：绿色可用、橙色处理中、红色失败。

交互原则

默认少展示：用户不需要理解检索细节。

一键展开：技术人员可查看完整链路。

可对比：不同模式结果要能并排比较。

可追踪：每次问答都有日志、Token、耗时。

组件清单

Metric Card

文档数、Chunk、延迟、成本、QPS。

Source Card

文件名、chunkId、score、内容摘要。

Trace Panel

Query、Retrieve、Rerank、Prompt、Answer。

Report Card

评测、性能、成本、失败样本。

面试展示脚本：按这 5 分钟讲就够

可直接背

“我没有把它做成一个普通 ChatBot，而是做成了一个可调试、可评测、可观测、可压测的企业级 RAG 实验平台。”

第一分钟：展示 Demo 总览页，说明系统规模、知识库、延迟、成本、评测得分。

第二分钟：进入问答页，演示答案、引用来源和可信度。

第三分钟：进入检索调试页，讲 Hybrid Search 和 Reranker 为什么提升效果。

第四分钟：进入评测实验页，讲 TopK 命中率、失败样本和优化闭环。

第五分钟：进入性能报告页，讲 QPS、P95、错误率、瓶颈和优化方案。

面试官可能追问，你这样回答

问题	回答重点
为什么不用单纯向量检索？	关键词、错误码、编号类问题更适合 BM25/Terms，Hybrid 能互补。
如何降低幻觉？	引用来源、只基于 Context 回答、低置信度提示、评测集验证。
如何评估效果？	TopK 命中率、答案相关性、上下文相关性、失败样本分析。
如何控制成本？	缓存、动态 topK、上下文预算、模型路由、Token 统计。
如何看系统极限？	构造企业数据，压测 QPS、并发、P95/P99、错误率和瓶颈。

落地优先级：先做能展示的闭环

后续开发建议

第一优先级：面试必须有

- Demo 总览页：把系统能力聚合到一个首页。
- 企业知识问答页：答案 + 引用来源 + 查看检索过程。
- 检索调试页：展示召回、重排、Prompt、Token、耗时。
- 性能报告页：展示造数据后的压测结果和瓶颈分析。

第二优先级：锦上添花

- 评测实验页：批量问题集、命中率、失败样本。
- 成本分析页：Token、模型成本、Embedding 成本。
- 权限与审计：知识库权限、访问日志、操作记录。
- 系统配置：模型 Provider、检索权重、Reranker 开关。

一句话收敛

不要继续堆很多零散功能。你的 RAG 项目应该围绕“企业知识问答 + 检索调试 + 效果评测 + 性能成本报告”这条主线做成一个完整演示闭环。

- 可演示
- 可解释
- 可评估
- 可压测
- 可面试讲清楚