

RAG 服务与 AI 求职 Agent 轻量版规划

第二阶段修订版：RAG 生产化 + 轻量 Agent 应用

版本：v3 | 规划目标：提升面试含金量、支持在线访问、为后续 Agent 项目打基础

1. 总体定位

本规划把两个项目明确分工：ai-rag-lab-platform 负责 RAG 服务能力，AI 求职 Agent 负责上层 Agent 应用能力。第二阶段的核心目标不是继续堆功能，而是把 RAG 项目做成可部署、可保护、可监控、可评估、可被 Agent 调用的知识服务底座。

项目	定位	重点能力	不重点做
ai-rag-lab-platform	RAG 服务 / 知识库实验平台	文档导入、检索、重排、评测、成本、性能、部署、服务化 API	不承载复杂 Agent 流程
AI 求职 Agent 轻量版	面向求职场景的轻量 Agent 应用	简历优化、岗位匹配、面试准备、任务编排、工具调用 RAG 服务	不做复杂多智能体平台、不做全自动投递机器人

2. 架构关系与部署建议

建议两个项目可以先部署在同一台阿里云 ECS 上，但必须做到服务隔离、路径隔离、配置隔离、日志隔离和资源隔离。后续访问量上来后，再拆分服务器。

维度	建议方案
域名 / 路径	RAG 服务使用 rag.xxx.com 或 /rag；求职 Agent 使用 agent.xxx.com 或 /agent
服务端口	RAG 后端、Agent 后端、前端、Nginx 分别使用独立端口和反向代理规则
数据库	同一 PostgreSQL 实例下使用不同 database 或 schema；避免表混在一起
配置	分别维护 rag.env、agent.env，模型 Key、API Key、数据库连接独立管理
调用关系	Agent 通过 API Key 调用 RAG 服务，例如 /api/rag/search、/api/rag/answer
日志	RAG 记录检索、token、耗时；Agent 记录任务、工具调用、用户操作链路
安全	公网入口统一由 Nginx 管理；RAG 内部 API 可限制只允许 Agent 或体验用户调用

3. 第一阶段已完成能力摘要

第一阶段 V0-V8 已经形成 RAG 实验平台完整闭环，后续第二阶段主要强化生产化能力。

能力类别	已完成内容
RAG 基础	文档导入、Chunk 分块、Embedding、PgVector、Naive RAG 问答
检索增强	BM25、Hybrid Search、Reranker
可观察	Debug 控制台、查询历史、指标、日志、慢查询分析
评测与实验	Evaluation、多模式对比、参数实验台、多组参数对比
产品入口	项目总览、能力导航、快速开始、版本路线图

4. 第二阶段 RAG 服务核心强化版规划

第二阶段先做面试含金量最高、又能支撑后续 AI 求职 Agent 的核心能力。以下天数按每天 8-10 小时投入估算。

版本	名称	优先级	目标	预计
V9	云部署与在线体验环境	P0	部署到阿里云，支持在线访问，前后端、Nginx、域名、HTTPS 打通	3-5 天
V10	访问保护与只读体验模式	P0	登录、体验账号、危险操作保护、接口限流，防止公网滥用	3-4 天
V11	Token 用量与成本监控	P0	统计问题、上下文、Prompt、输出 token，并预估费用	4-5 天
V12	RAG 性能压测与瓶颈分析	P0	压测 VECTOR/BM25/HYBRID/Reranker，输出 P90/P95 与瓶颈分析	4-5 天
V13	Docker Compose + 一键部署	P0	容器化后端、前端、PostgreSQL、PgVector、ES、Nginx	3-5 天
V14	RAG 服务化接口 / Agent 调用 API	P0	为外部 Agent 提供标准化 search/answer API、API Key、traceld	4-5 天
V15	本地模型接入与模型路由	P1	支持 Local/Cloud/Mock/AUTO 路由，降低成本并提供降级能力	5-7 天
V16	CI/CD 轻量发布流程	P1	GitHub Actions 构建、测试、镜像构建或 SSH 部署，先做轻量版	2-4 天
V19	简历包装初版	P0	README、架构图、截图、在线地址、简历描述、面试话术	3-4 天

第二阶段核心强化版预计 31-44 个工作日。若每天投入约 10 小时，比较稳妥的周期是 3-4 周；如果只做到可面试版本，可优先完成 V9-V14 和 V19。

5. RAG 服务后续增强项

以下能力可以在核心强化版之后继续做。它们同样有面试价值，但不应阻塞第二阶段核心目标。

版本	名称	建议顺序	说明
V17	上下文 Token 预算与溢出控制	建议做	控制 Prompt 过长、成本过高、上下文污染
V18	文档增量更新与版本管理	建议做	文档指纹去重、单文档增量重建 Chunk/Embedding/ES
V20	最小权限 RAG 与知识库访问隔离	建议做	按角色或知识库可见范围控制检索权限
V21	页面视觉与产品体验优化	可选	统一页面风格、空状态、加载态、错误态，提高在线体验

6. AI 求职 Agent 轻量版规划

AI 求职 Agent 项目只做轻量版，重点体现 Agent 思维：任务规划、工具调用、求职流程辅助、调用 RAG 服务获取上下文。不要做成复杂多智能体平台，也不要做全自动投递系统。

阶段	名称	目标	预计
A1	项目骨架与基础页面	创建轻量 Agent 前后端，包含首页、任务面板、设置页	2 天
A2	接入 RAG 服务工具	通过 API Key 调用 RAG 服务，查询简历知识库、项目经验库、面试题库	2-3 天
A3	岗位 JD 分析	输入岗位描述，拆解技能要求、经验要求、匹配关键词	2-3 天
A4	简历匹配与优化建议	结合 RAG 返回的个人项目/经验上下文，输出简历优化建议	3-4 天
A5	面试准备助手	基于岗位和简历生成面试问题、回答要点、项目讲解话术	2-3 天
A6	轻量任务编排	实现计划-调用工具-整理结果的简单 Agent 流程，不做复杂多 Agent	3-4 天
A7	求职记录与进度看板	记录岗位、匹配度、准备状态、面试问题，不做完整 CRM	2-3 天
A8	项目包装初版	README、使用路径、截图、面试讲解材料	2 天

AI 求职 Agent 轻量版预计 18-24 个工作日。最佳启动点是 RAG 服务完成 V14 Agent 调用 API 之后，因为那时 Agent 可以稳定调用 RAG 服务。

7. AI 求职 Agent 轻量版边界

做	不做
岗位 JD 解析、技能关键词提取	不做全自动批量投递
简历匹配分析和优化建议	不接管招聘网站账号

面试问题生成和项目话术整理	不做复杂浏览器自动化
调用 RAG 服务查询个人经验和项目知识库	不重复实现知识库系统
轻量任务编排和结果汇总	不做多智能体平台和复杂长期记忆

8. 两个项目的推荐执行顺序

推荐先完成 RAG 服务核心强化版，再启动 AI 求职 Agent 轻量版。这样 Agent 不需要重复实现知识库能力，而是把 RAG 服务当作工具调用。

顺序	阶段	说明	预计
1	RAG V9-V10	先部署上线并做好访问保护	6-9 天
2	RAG V11-V12	完成 Token 成本和性能压测，建立生产化观测能力	8-10 天
3	RAG V13-V14	完成一键部署和 Agent 调用 API	7-10 天
4	RAG V15-V16	本地模型路由和轻量 CI/CD	7-11 天
5	RAG V19 初版	简历材料、README、截图、在线地址	3-4 天
6	AI 求职 Agent A1-A8	轻量版 Agent 应用，调用 RAG 服务能力	18-24 天

9. 面试主线叙事

面试时建议把两个项目讲成一个组合：RAG 服务是底座，AI 求职 Agent 是上层应用。

- RAG 服务体现：知识库、检索、重排、评测、参数实验、成本、性能、部署和服务化。
- AI 求职 Agent 体现：任务规划、工具调用、岗位分析、简历优化、面试准备和流程自动化。
- 两个项目通过 API 解耦：Agent 不自己做知识库，而是调用 RAG 服务获取可靠上下文。
- 部署上可以先共用一台服务器，但服务、路径、配置、日志、权限要隔离。
- 这比单个 RAG 项目或单个 Agent 项目更有说服力，因为它展示了从底层知识服务到上层 Agent 应用的完整链路。

10. 总体时间预估

内容	预计工作日	每天 10 小时估算
RAG 服务核心强化版 V9-V16 + V19	31-44 天	约 3-4 周
AI 求职 Agent 轻量版 A1-A8	18-24 天	约 2-3 周
两个项目合计	49-68 天	约 5-7 周

如果目标是尽快面试，可以先完成 RAG V9-V14 + V19，再做 AI 求职 Agent 的 A1-A5，形成可讲的组合项目。

11. 最终建议

- 第二阶段先专注 RAG 服务生产化：部署、保护、成本、性能、一键部署、Agent API、模型路由。
- AI 求职 Agent 做轻量版，重点体现 Agent 调用工具和完成任务的能力，不要做成复杂平台。

- RAG 服务和 Agent 项目可以共用服务器，但必须做好服务隔离和配置隔离。
- 面试时突出“RAG 服务底座 + Agent 应用层”的组合能力，这比单点功能更有含金量。